

**PENGEMBANGAN SISTEM REKOMENDASI OLAHRAGA  
PERSONAL UNTUK NON-ATLET MENGGUNAKAN METODE  
CONTENT-BASED FILTERING BERBASIS PROFIL PENGGUNA**



**DISUSUN OLEH :  
SURYA DWI SATRIA  
NIM. 434231048**

**PROGRAM STUDI D4 TEKNIK INFORMATIKA  
DEPARTEMEN TEKNIK  
FAKULTAS VOKASI  
UNIVERSITAS AIRLANGGA  
2026**

## DAFTAR ISI

|                                                          |           |
|----------------------------------------------------------|-----------|
| <b>DAFTAR ISI.....</b>                                   | <b>2</b>  |
| <b>DAFTAR TABEL.....</b>                                 | <b>4</b>  |
| <b>DAFTAR GAMBAR.....</b>                                | <b>5</b>  |
| <b>BAB I PENDAHULUAN.....</b>                            | <b>1</b>  |
| 1.1 Latar Belakang.....                                  | 1         |
| 1.2 Rumusan Masalah.....                                 | 5         |
| 1.3 Tujuan Penelitian.....                               | 5         |
| 1.4 Manfaat Penelitian.....                              | 6         |
| 1.4.1. Manfaat Teoritis.....                             | 6         |
| 1.4.2 Manfaat Praktis.....                               | 6         |
| 1.4.3 Manfaat Sosial.....                                | 6         |
| 1.5 Batasan Masalah.....                                 | 6         |
| <b>BAB II TINJAUAN PUSTAKA.....</b>                      | <b>7</b>  |
| 2.1 Landasan Teori.....                                  | 7         |
| 2.1.1 Aktivitas Fisik dan Non-Athlet.....                | 7         |
| 2.1.2 Sistem Rekomendasi.....                            | 8         |
| 2.2.3 Content-Based Filtering (CBF).....                 | 8         |
| 2.1.4 Machine Learning.....                              | 9         |
| 2.1.5 Preprocessing Data dan Feature Engineering.....    | 9         |
| 2.1.6 Weighted Cosine Similarity (WCS).....              | 10        |
| 2.1.7 Feedback Loop dan Continuous Profile Modeling..... | 11        |
| 2.1.8 Metrik Evaluasi Sistem.....                        | 12        |
| 2.1.9 Python.....                                        | 13        |
| 2.1.10 PostgreSQL.....                                   | 14        |
| 2.2 Penelitian Terdahulu.....                            | 15        |
| <b>BAB III METODE PENELITIAN.....</b>                    | <b>17</b> |
| 3.1 Tempat dan Waktu Penelitian.....                     | 17        |
| 3.2 Alat dan Bahan Penelitian.....                       | 17        |
| 3.2.1 Perangkat Keras.....                               | 18        |
| 3.2.2 Perangkat Lunak.....                               | 18        |
| 3.3 Metode Penelitian.....                               | 19        |
| 3.3.1 Tahap Identifikasi dan Analisis Masalah.....       | 19        |
| 3.3.2 Pengembangan Model.....                            | 21        |
| 3.3.3 Perancangan Sistem.....                            | 27        |

|                                          |           |
|------------------------------------------|-----------|
| 3.3.4 Pengujian dan Evaluasi Sistem..... | 36        |
| <b>DAFTAR PUSTAKA.....</b>               | <b>37</b> |

## DAFTAR TABEL

|                                                           |    |
|-----------------------------------------------------------|----|
| Tabel 2.1 Penelitian Terdahulu.....                       | 15 |
| Tabel 3.1 Timeline kegiatan.....                          | 17 |
| Tabel 3.2 Perangkat Keras.....                            | 18 |
| Tabel 3.3 Perangkat Lunak.....                            | 18 |
| Tabel 3.4 Kategorisasi BMI Standar WHO.....               | 22 |
| Tabel 3.5 Contoh One-Hot Encoding Atribut Level.....      | 23 |
| Tabel 3.6 Aturan Profile-Based Filtering.....             | 24 |
| Tabel 3.7 Skema Pembobotan Berdasarkan Fitness Goal.....  | 25 |
| Tabel 3.8 Penyesuaian Bobot Berdasarkan Kategori BMI..... | 25 |
| Tabel 3.9 Jenis Implicit Feedback dan Sinyalnya.....      | 26 |

## DAFTAR GAMBAR

|                                             |    |
|---------------------------------------------|----|
| Gambar 3.1 Alur Sistem.....                 | 21 |
| Gambar 3.2 Use Case Diagram.....            | 28 |
| Gambar 3.3 Conceptual Data Model (CDM)..... | 29 |
| Gambar 3.4 Physical Data Model (PDM).....   | 30 |
| Gambar 3.5 Halaman Onboarding.....          | 31 |
| Gambar 3.6 Halaman Dashboard Utama.....     | 32 |
| Gambar 3.7 Halaman Statistik Aktivitas..... | 33 |
| Gambar 3.8 Halaman Katalog Latihan.....     | 34 |
| Gambar 3.9 Halaman Pusat Notifikasi.....    | 35 |

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Aktivitas fisik memiliki peran penting dalam menjaga keseimbangan kesehatan fisik dan mental seseorang. Aktivitas yang dilakukan secara teratur dapat membantu tubuh dalam menjaga fungsi organ, meningkatkan kebugaran, serta mendukung kesehatan psikologis. Menurut Lee et al. (2012) dalam *The Lancet*, kurangnya aktivitas fisik secara langsung berkontribusi pada meningkatnya risiko penyakit tidak menular seperti diabetes tipe 2, kanker, dan penyakit kardiovaskular. Lebih lanjut, Coppens et al. (2024) menegaskan bahwa aktivitas fisik yang teratur terbukti memperpanjang harapan hidup dan menjaga fungsi metabolisme tubuh secara optimal. Namun, pada praktiknya, tidak semua individu mampu mempertahankan kebiasaan berolahraga secara konsisten. Berdasarkan laporan *Global Status Report on Physical Activity* dari WHO (2022), sekitar 81% remaja dan 27,5% orang dewasa di seluruh dunia masih tergolong kurang aktif secara fisik. Di Indonesia, survei *Riskesmas* (2018) menunjukkan bahwa sekitar 33,5% penduduk usia 10 tahun ke atas termasuk dalam kategori kurang aktif. Pola hidup modern yang didominasi oleh aktivitas duduk, penggunaan teknologi, serta minimnya pergerakan fisik menjadi salah satu faktor yang menyebabkan rendahnya tingkat aktivitas fisik masyarakat.

Berdasarkan laporan *World Health Organization* (WHO, 2020), WHO merekomendasikan minimal 150 - 300 menit aktivitas fisik intensitas sedang per minggu bagi orang dewasa, atau setara 75 - 150 menit aktivitas intensitas tinggi. Namun, sekitar 1,4 miliar orang dewasa di seluruh dunia setara dengan lebih dari 27,5% populasi orang dewasa global masih belum memenuhi rekomendasi tersebut (WHO, 2022). Kondisi ini menunjukkan bahwa masih terdapat kesenjangan antara pengetahuan akan pentingnya olahraga dan penerapannya dalam kehidupan sehari-hari. Banyak individu menyadari manfaat olahraga,

namun mengalami kesulitan dalam memulai maupun mempertahankan rutinitas tersebut.

Dalam konteks ini, istilah non-atlet merujuk pada individu yang tidak menjalani program latihan terstruktur secara profesional dan tidak berkompetisi dalam olahraga formal. Bagi non-atlet, olahraga umumnya dipahami sebagai aktivitas fisik yang dilakukan untuk tujuan kesehatan umum, kebugaran, atau rekreasi bukan sebagai profesi. Menurut Agans et al. (2025), non-atlet seringkali tidak memiliki pengetahuan teknis yang memadai tentang prinsip latihan yang aman dan efektif, sehingga mereka sangat membutuhkan panduan atau rekomendasi yang disesuaikan dengan kondisi fisik mereka. Tanpa panduan yang tepat, non-atlet berisiko mengalami cedera akibat pemilihan olahraga yang tidak sesuai, atau justru berhenti berolahraga karena merasa aktivitas yang dilakukan tidak relevan dengan kemampuan dan kebutuhan mereka. Hal ini mendorong kebutuhan akan aplikasi atau sistem digital yang dapat memberikan rekomendasi olahraga yang aman, personal, dan mudah dipahami oleh pengguna awam. Hasil observasi awal dan wawancara terhadap beberapa responden non-atlet usia 18–60 tahun menunjukkan bahwa hambatan utama dalam berolahraga bukan hanya pada keterbatasan waktu, tetapi juga pada ketidaktahuan dalam memilih jenis olahraga yang sesuai dengan kondisi tubuh. Sebagian responden mengungkapkan kebingungan dalam menentukan aktivitas yang aman dan efektif, sementara responden lainnya menghentikan rutinitas olahraga karena merasa aktivitas yang dilakukan terlalu berat atau tidak sesuai dengan kemampuan fisik mereka.

Di sisi lain, perkembangan teknologi telah melahirkan berbagai aplikasi kebugaran yang menawarkan rekomendasi aktivitas olahraga, seperti Nike Training Club, Freeletics, dan MyFitnessPal. Meskipun populer, aplikasi - aplikasi tersebut umumnya memberikan program latihan yang bersifat standar dan tidak sepenuhnya disesuaikan dengan karakteristik individu pengguna.

Aplikasi seperti Nike Training Club menawarkan program berdasarkan tujuan umum (penurunan berat badan, kekuatan, dll.), namun tidak mempertimbangkan kondisi kesehatan spesifik atau batasan kemampuan fisik pengguna pemula. Freeletics menggunakan pendekatan progresif, namun intensitasnya seringkali dinilai terlalu tinggi bagi non-atlet. Sedangkan MyFitnessPal lebih berfokus pada pencatatan kalori daripada rekomendasi program latihan yang dipersonalisasi. Rekomendasi yang tidak disesuaikan dengan faktor seperti usia, indeks massa tubuh (BMI), preferensi olahraga, serta kondisi kesehatan berpotensi menurunkan motivasi pengguna dan meningkatkan risiko cedera. Penelitian sebelumnya menunjukkan bahwa pendekatan rekomendasi yang bersifat personal memiliki pengaruh positif terhadap konsistensi dan keterlibatan pengguna dalam jangka panjang (Zhao et al., 2020).

Sejumlah penelitian terkini telah mengkaji penerapan sistem rekomendasi dalam domain kebugaran dan olahraga. Penelitian dari Gao et al. pada tahun (2024) “Enhancing Personalized Exercise Recommendation with Student and Exercise Portraits” menunjukkan bahwa pemanfaatan karakteristik pengguna dan aktivitas olahraga mampu menghasilkan rekomendasi yang lebih relevan dan meningkatkan keterlibatan pengguna. Selain itu, penelitian dari Chatterjee et al. pada tahun 2023 berjudul “An Automatic and Personalized Recommendation Modelling in Activity eCoaching with Deep Learning and Ontology” mengembangkan sistem rekomendasi berbasis pembelajaran mendalam dan ontologi semantik untuk menyesuaikan rekomendasi aktivitas berdasarkan konteks pengguna. Adapun terkait panduan olahraga yang cocok untuk pemula non-atlet, Agans et al. (2025) dalam penelitiannya “Supporting Physical Activity Adoption through Recommender System Technology: A Pilot Study” menunjukkan bahwa pengguna pemula dengan tingkat kebugaran rendah membutuhkan rekomendasi dengan intensitas terukur yang disesuaikan secara bertahap. Lebih jauh, Coppens et al. (2024) dalam penelitian longitudinal

berjudul 'Exploring the Added Effect of Three Recommender System Techniques in Mobile Health Interventions for Physical Activity' yang menjadi acuan utama penelitian ini, membuktikan bahwa penerapan tiga teknik personalisasi berbasis sistem rekomendasi yakni mood micro-profile, content-based recommender, dan contextual post-filter secara signifikan meningkatkan motivasi pengguna, rating rekomendasi, dan durasi aktivitas fisik yang dilakukan. Terlepas dari banyaknya pekerjaan yang telah dilakukan pada sistem rekomendasi kebugaran seperti pendekatan *deep learning*, ontologi, dan intervensi multi-teknik yang kompleks, belum ada studi sebelumnya yang menyelidiki secara komprehensif sebuah sistem sederhana berbasis profil fisik spesifik yang ditujukan khusus untuk non-atlet dengan kondisi *cold-start*.

Berdasarkan permasalahan tersebut, diperlukan sebuah sistem rekomendasi olahraga yang dirancang khusus untuk pengguna non-atlet dengan mempertimbangkan karakteristik individu serta aspek keamanan latihan. Dalam penelitian ini, metode Content-Based Filtering (CBF) dipilih sebagai pendekatan utama dalam membangun sistem rekomendasi.

Pemilihan metode CBF didasarkan pada kemampuannya dalam menghasilkan rekomendasi yang bersifat personal dengan mencocokkan atribut profil pengguna dan atribut item olahraga secara langsung. Berbeda dengan metode collaborative filtering yang bergantung pada data interaksi dari banyak pengguna, CBF tidak memerlukan data historis dalam jumlah besar sehingga lebih sesuai untuk konteks pengguna non-atlet yang cenderung memiliki data terbatas (*cold-start condition*).

Selain itu, CBF memungkinkan sistem untuk mempertimbangkan faktor-faktor penting seperti usia, indeks massa tubuh (BMI), preferensi olahraga, dan kondisi kesehatan secara eksplisit, sehingga rekomendasi yang dihasilkan lebih relevan, aman, dan mudah diinterpretasikan. Dibandingkan

dengan pendekatan berbasis *deep learning* yang umumnya membutuhkan kompleksitas tinggi dan data skala besar, CBF menawarkan solusi yang lebih sederhana namun tetap efektif dalam menghasilkan rekomendasi yang sesuai dengan kebutuhan pengguna.

Oleh karena itu, penelitian ini berfokus pada pengembangan sistem rekomendasi olahraga personal berbasis Content-Based Filtering yang dirancang khusus untuk pengguna non-atlet, dengan tujuan menghasilkan rekomendasi aktivitas fisik yang aman, relevan, dan sesuai dengan kondisi individu.

## **1.2 Rumusan Masalah**

Rumusan masalah yang diangkat dalam penelitian ini terdiri dari dua pertanyaan utama, yaitu:

1. Bagaimana merancang sistem rekomendasi olahraga harian berbasis karakteristik pengguna non-atlet dengan memodelkan profil pengguna dan atribut aktivitas olahraga menggunakan pendekatan Content-Based Filtering?
2. Bagaimana mengukur performa sistem rekomendasi menggunakan matrik evaluasi precision dan recall berbasis simulasi dataset?

## **1.3 Tujuan Penelitian**

Tujuan dari penelitian ini adalah sebagai berikut:

1. Merancang dan membangun sistem rekomendasi olahraga harian yang disesuaikan dengan karakteristik pengguna non-atlet.
2. Menerapkan metode Content-Based Filtering berbasis profil pengguna (usia, BMI, preferensi olahraga, dan kondisi kesehatan) untuk menghasilkan rekomendasi aktivitas fisik yang personal, aman, dan sesuai dengan kemampuan fisik pengguna non-atlet.
3. Mengevaluasi kinerja sistem rekomendasi menggunakan metrik precision dan recall.

## **1.4 Manfaat Penelitian**

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

### **1.4.1. Manfaat Teoritis**

Memberikan kontribusi pada pengembangan sistem rekomendasi di bidang kesehatan dan kebugaran, khususnya penerapan metode Content-Based Filtering dalam domain olahraga non-atlet.

### **1.4.2 Manfaat Praktis**

Membantu non-atlet memperoleh rekomendasi olahraga yang aman, sesuai kondisi tubuh, dan tidak monoton sehingga meningkatkan engagement dalam berolahraga.

### **1.4.3 Manfaat Sosial**

Mendukung peningkatan kualitas hidup masyarakat melalui aktivitas fisik yang lebih terarah dan berkelanjutan, sehingga dapat membantu menurunkan risiko penyakit tidak menular.

## **1.5 Batasan Masalah**

1. Penelitian difokuskan pada pengguna non-atlet dengan tingkat kebugaran umum, bukan populasi dengan kebutuhan medis khusus atau atlet profesional.
2. Metode rekomendasi yang digunakan adalah Content-Based Filtering tanpa menggabungkan metode collaborative filtering atau hybrid dengan pertimbangan kesesuaian terhadap ketersediaan data.
3. Variabel profil pengguna yang digunakan meliputi: usia, jenis kelamin, BMI, preferensi olahraga, dan kondisi kesehatan umum.
4. Data yang digunakan dalam penelitian ini berasal dari dataset publik pada platform Kaggle yang digunakan sebagai data simulasi, sehingga tidak melibatkan data pengguna secara langsung.
5. Evaluasi sistem dilakukan menggunakan pendekatan simulasi berbasis dataset dan tidak mencakup uji coba lapangan secara langsung pada pengguna.

## **BAB II**

### **TINJAUAN PUSTAKA**

#### **2.1 Landasan Teori**

Landasan teori mencakup konsep dan teori yang mendasari pelaksanaan penelitian ini.

##### **2.1.1 Aktivitas Fisik dan Non-Athlet**

Aktivitas fisik memiliki peran penting dalam menjaga keseimbangan kesehatan fisik dan mental seseorang. Aktivitas yang dilakukan secara teratur dapat membantu tubuh dalam menjaga fungsi organ, meningkatkan kebugaran, serta mendukung kesehatan psikologis. Menurut Lee et al. (2012) dalam *The Lancet*, kurangnya aktivitas fisik secara langsung berkontribusi pada meningkatnya risiko penyakit tidak menular seperti diabetes tipe 2, kanker, dan penyakit kardiovaskular. Lebih lanjut, Coppens et al. (2024) menegaskan bahwa aktivitas fisik yang teratur terbukti memperpanjang harapan hidup dan menjaga fungsi metabolisme tubuh secara optimal. Berdasarkan laporan *World Health Organization* (WHO, 2020), WHO merekomendasikan minimal 150–300 menit aktivitas fisik intensitas sedang per minggu bagi orang dewasa, atau setara dengan 75–150 menit aktivitas intensitas tinggi. Menurut WHO (2023), aktivitas fisik didefinisikan sebagai setiap gerakan tubuh yang dihasilkan oleh otot rangka dan memerlukan pengeluaran energi, termasuk berjalan, bersepeda, atau aktivitas rekreasi lainnya.

Dalam konteks sistem ini, istilah non-atlet merujuk pada individu yang tidak menjalani program latihan terstruktur secara profesional dan tidak berkompetisi dalam olahraga formal. Bagi non-atlet, olahraga umumnya dipahami sebagai aktivitas fisik yang dilakukan untuk tujuan kesehatan umum, kebugaran, atau rekreasi, bukan sebagai profesi. Menurut Agans et al. (2025), non-atlet seringkali tidak memiliki pengetahuan teknis yang memadai tentang

prinsip latihan yang aman dan efektif, sehingga mereka sangat membutuhkan panduan atau rekomendasi yang disesuaikan dengan kondisi fisik mereka. Pengguna dengan tingkat kebugaran rendah (non-atlet atau individu dengan obesitas) cenderung membutuhkan rekomendasi olahraga dengan intensitas terukur dan aman, bukan aktivitas yang terlalu berat. Zhao et al. (2020) menambahkan bahwa rekomendasi olahraga yang sesuai dengan preferensi dapat meningkatkan motivasi dan kepatuhan latihan dalam jangka panjang.

### **2.1.2 Sistem Rekomendasi**

Sistem rekomendasi (recommender system) adalah sistem cerdas yang bertujuan memberikan rekomendasi atau saran kepada pengguna berdasarkan preferensi atau riwayat interaksi pengguna terhadap suatu item (misalnya film, musik, aktivitas, atau produk). Sistem ini bekerja dengan menganalisis data dan memilih item yang paling relevan sehingga dapat membantu pengguna dalam pengambilan keputusan. Menurut Gao et al. (2024), penggunaan recommender system dalam bidang olahraga mampu meningkatkan relevansi rekomendasi terkait aktivitas fisik, karena sistem mempertimbangkan karakteristik pengguna serta fitur aktivitas olahraga itu sendiri.

### **2.2.3 Content-Based Filtering (CBF)**

Metode dalam sistem rekomendasi yang memberikan saran kepada pengguna dengan mengevaluasi kemiripan antara konten atau atribut dari suatu item dengan preferensi yang tercatat dalam profil pengguna. Berbeda dengan collaborative filtering yang bergantung pada perilaku komunitas pengguna, CBF bekerja secara independen dengan memanfaatkan deskripsi eksplisit dari item dan data personal pengguna. Dalam konteks penelitian ini, CBF digunakan untuk mencocokkan profil fisik pengguna (seperti usia, jenis kelamin, dan BMI) dengan atribut aktivitas olahraga (seperti intensitas, durasi, dan bagian tubuh yang dilatih).

### 2.1.4 Machine Learning

Sistem rekomendasi berbasis Content-Based Filtering merupakan bagian dari paradigma Machine Learning. Pendekatan ini memanfaatkan pemodelan data untuk mengenali pola preferensi pengguna secara otomatis melalui ekstraksi fitur. Dibandingkan dengan pendekatan berbasis deep learning yang umumnya membutuhkan kompleksitas komputasi tinggi dan data skala besar, algoritma matematika pada CBF menawarkan solusi yang lebih sederhana, efisien, namun tetap efektif dalam menghasilkan rekomendasi yang sesuai dengan kebutuhan personal non-atlet.

### 2.1.5 Preprocessing Data dan Feature Engineering

Proses penyiapan data dalam sistem rekomendasi ini dibagi menjadi dua tahapan utama, yaitu *data preprocessing* dan *feature engineering*. Tahap *data preprocessing* meliputi pembersihan data dari keempat dataset Kaggle. Langkah-langkahnya mencakup penanganan nilai kosong (*handling missing values*) di mana nilai kosong pada atribut numerik diimputasi menggunakan nilai median, sedangkan atribut kategorikal diimputasi menggunakan modus. Selanjutnya dilakukan penghapusan data duplikat untuk menghindari bias model. Perhitungan Indeks Massa Tubuh (BMI) dilakukan menggunakan formula:

$$BMI = \frac{BB}{TB^2}$$

Keterangan:

$BMI = \text{Body Mass Index (kg/m}^2\text{)}$

$BB = \text{Berat Badan (kg)}$

$TB = \text{Tinggi Badan (m)}$

Nilai BMI kemudian diklasifikasikan ke dalam kategori standar WHO, yaitu *Underweight* ( $< 18,5$ ), *Normal* ( $18,5\text{--}24,9$ ), *Overweight* ( $25,0\text{--}29,9$ ), dan *Obese* ( $\geq 30,0$ ).

Tahap *feature engineering* berfokus pada konversi atribut menjadi representasi vektor numerik. Proses *scaling* untuk atribut numerik menggunakan *Min-Max Scaling* dengan formula:

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Normalisasi ini mengubah seluruh nilai numerik ke rentang [0, 1] agar tidak ada atribut yang mendominasi perhitungan akibat perbedaan skala nilai yang besar. Untuk atribut kategorikal seperti *Level* (Beginner, Intermediate, Expert), digunakan teknik *One-Hot Encoding* untuk mengubahnya menjadi representasi biner.

### 2.1.6 Weighted Cosine Similarity (WCS)

Inti dari algoritma CBF adalah menghitung jarak atau sudut antar vektor fitur untuk menentukan tingkat kemiripan. Penelitian ini menerapkan *Weighted Cosine Similarity* (WCS), yaitu pengembangan dari *cosine similarity* standar yang memberikan bobot berbeda ( $w_k$ ) pada setiap atribut berdasarkan tingkat kepentingan relatifnya terhadap tujuan kebugaran (*fitness goal*) dan kategori BMI pengguna. Secara matematis, formula kemiripan WCS dihitung dengan rumus:

$$WCS(U, I) = \frac{\sum_{k=1}^K (w_k \cdot u_k \cdot i_k)}{\sqrt{\sum_{k=1}^K (w_k \cdot u_k^2)} \cdot \sqrt{\sum_{k=1}^K (w_k \cdot i_k^2)}}$$

Keterangan:

- $WCS(U, I)$  = Skor kemiripan antara pengguna  $U$  dan item olahraga  $I$  (rentang 0–1)
- $w_k$  = Bobot adaptif untuk atribut ke- $k$
- $u_k$  = Nilai atribut ke- $k$  pada vektor fitur pengguna
- $i_k$  = Nilai atribut ke- $k$  pada vektor fitur item olahraga
- $K$  = Jumlah total atribut

Skor WCS dihitung untuk setiap item olahraga yang telah lolos tahap penyaringan keamanan (*pre-filtering*) berbasis aturan WHO, kemudian diurutkan secara menurun (*descending*) untuk menyajikan daftar rekomendasi Top-N harian.

### 2.1.7 Feedback Loop dan Continuous Profile Modeling

Mekanisme *feedback loop* berfungsi untuk memperbarui profil dan preferensi pengguna secara otomatis berdasarkan interaksi yang dilakukan oleh pengguna (*implicit feedback*). Jenis interaksi yang dicatat mencakup sinyal positif (seperti melakukan klik, memberikan rating  $\geq 4$  bintang, atau menyelesaikan aktivitas olahraga) dan sinyal negatif (seperti mengabaikan/*skip* rekomendasi atau memberikan rating  $\leq 2$  bintang). Pembaruan bobot vektor pengguna dilakukan secara berkala menggunakan formula:

$$w_k(t+1) = w_k(t) + \eta \cdot \sum_j (feedback_j \cdot i_{jk})$$

Keterangan:

- $w_k(t+1)$  = Bobot atribut ke- $k$  pada iterasi berikutnya
- $w_k(t)$  = Bobot atribut ke- $k$  saat ini
- $\eta$  = *Learning rate* (tetapan default: 0,01)
- $feedback_j$  = Nilai sinyal *feedback* untuk item ke- $j$
- $i_{jk}$  = Nilai atribut ke- $k$  pada item ke- $j$  yang diberi *feedback*

Setiap nilai bobot hasil pembaruan dibatasi secara ketat pada rentang  $[0,1-2,0]$  dengan batas perubahan maksimal  $\pm 10\%$  per iterasi (*clamping*) demi menjaga stabilitas rekomendasi model.

### 2.1.8 Metrik Evaluasi Sistem

Evaluasi sistem dilakukan untuk mengukur efektivitas algoritma *Content-Based Filtering* dalam memberikan rekomendasi yang relevan. Berdasarkan literatur *Information Retrieval*, metrik yang digunakan adalah *Precision*, *Recall*, dan *F1-Score*.

#### 1. Precision

*Precision* mengukur tingkat keakuratan sistem dengan membandingkan jumlah item relevan yang direkomendasikan terhadap total item yang diberikan oleh sistem. Secara matematis, rumus *Precision* adalah:

$$Precision = \frac{|Relevant \cap Recommended|}{|Recommended|}$$

#### 2. Recall

*Recall* mengukur kemampuan sistem dalam menemukan kembali seluruh item relevan yang ada di dalam dataset. Rumus *Recall* didefinisikan sebagai:

$$Recall = \frac{|Relevant \cap Recommended|}{|Relevant|}$$

#### 3. F1-Score

*F1-Score* digunakan untuk melihat rata-rata harmonik dari *Precision* dan *Recall* guna mendapatkan gambaran performa sistem yang lebih seimbang:

$$F1-Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

### 2.1.9 Python

Python digunakan sebagai bahasa pemrograman utama dalam penelitian ini karena dukungannya yang luas terhadap ekosistem pengolahan data vektor, rekayasa fitur, dan implementasi algoritma matematika. Berikut adalah rincian pustaka (*library*) Python yang digunakan sebagai sarana pendukung dalam pelaksanaan penelitian ini beserta fungsi spesifiknya:

1. **Pandas:** Berfungsi sebagai pustaka tingkat tinggi untuk manipulasi dan analisis data struktur. Dalam penelitian ini, Pandas digunakan untuk membaca berkas dataset berbentuk CSV, melakukan manipulasi komponen *dataframe*, operasi penggabungan (*merge dataset*), serta penanganan tahap pembersihan data (*data cleaning*).
2. **NumPy:** Berfungsi untuk mendukung komputasi saintifik berbasis larik (*array*) multidimensi. NumPy digunakan untuk mengelola operasi vektor dan matriks matematika tingkat tinggi secara efisien saat melakukan perhitungan kedekatan sudut menggunakan formula *Weighted Cosine Similarity*.
3. **Scikit-learn:** Berfungsi sebagai pustaka utama untuk pemodelan *machine learning*. Pustaka ini digunakan untuk melakukan transformasi skala fitur numerik (*MinMaxScaler*), penyandian atribut kategorikal (*OneHotEncoder*), kalkulasi skor jarak kemiripan (*cosine\_similarity*), hingga menghitung nilai evaluasi performa model otomatis (*precision\_score*, *recall\_score*, dan *f1\_score*).
4. **Matplotlib:** Berfungsi sebagai pustaka dasar untuk visualisasi data dua dimensi (*2D plots*). Matplotlib digunakan dalam penelitian ini untuk membangun grafik evaluasi performa akurasi sistem, khususnya visualisasi perbandingan nilai *precision*, *recall*, dan *F1-score* pada berbagai tingkat Top-N.

5. **Seaborn**: Berfungsi sebagai pustaka visualisasi statistik berbasis visual tingkat tinggi. Seaborn digunakan untuk menampilkan diagram *heatmap* korelasi antar atribut profil fisik serta melakukan visualisasi terhadap pola distribusi data awal dari dataset.
6. **Flask** : sebuah *micro framework* berbasis Python yang digunakan untuk membangun sisi *backend* aplikasi. Dalam penelitian ini, *Flask* berfungsi sebagai penyedia layanan *RESTful API* (Application Programming Interface). *Flask* akan menerima permintaan (*request*) dari sisi *frontend*, berinteraksi dengan database PostgreSQL menggunakan *library* Psycopg2, memproses data melalui algoritma *Content-Based Filtering*, dan mengembalikan hasil luaran berupa format JSON (*JavaScript Object Notation*).
7. **Psycopg2**: Berfungsi sebagai komponen *database driver* atau *adapter* resmi untuk PostgreSQL di Python. Pustaka ini digunakan untuk menjembatani gerbang koneksi pemrograman sistem serta memproses pengiriman perintah *query* manipulasi data menuju basis data basis data relasional.

#### 2.1.10 PostgreSQL

PostgreSQL berperan sebagai sistem manajemen basis data relasional (*Relational Database Management System*) utama di sisi *server*. PostgreSQL digunakan untuk menyimpan data kredensial akun pengguna, parameter komponen profil fisik awal (usia, tinggi badan, berat badan, kondisi kesehatan), riwayat aktivitas olahraga harian yang berhasil diselesaikan, serta pencatatan log interaksi *feedback* untuk keperluan pembaruan bobot model pada modul *feedback loop*.

## 2.2 Penelitian Terdahulu

**Tabel 2.1 Penelitian Terdahulu**

| No | Judul Penelitian                                                                                                                                                                                     | Metode yang Digunakan                                                                             | Variabel yang Digunakan                                                       | Hasil Penelitian                                                                                                                                                       |
|----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | <i>Exploring the added effect of three recommender system techniques in mobile health interventions for physical activity</i> — Coppens, I., De Pessemier, T., & Martens, L. (Referensi Utama), 2024 | Mood micro-profile filter + Content-Based Recommender + Contextual Post-Filter (RCT longitudinal) | Mood, motivasi, situasi kontekstual, profil pengguna, atribut aktivitas fisik | Tiga teknik personalisasi RS meningkatkan motivasi, rating, durasi & intensitas aktivitas fisik serta mengurangi dropout pengguna. Menjadi acuan utama penelitian ini. |
| 2  | <i>Enhancing personalized exercise recommendation with student and exercise portraits</i> — Gao, W. W., Ma, H. F., Zhao, Y., Wang, J., & Tian, Q. H. , 2024                                          | Recommender System dengan model Student & Exercise Portraits                                      | Data profil pengguna + karakteristik aktivitas olahraga                       | Model meningkatkan akurasi, kebaruan (novelty), dan keberagaman rekomendasi olahraga.                                                                                  |
| 3  | <i>An automatic and personalized recommendation modelling in activity eCoaching with deep learning and</i>                                                                                           | Sistem rekomendasi berbasis Deep Learning + Ontologi Semantik                                     | Data sensor aktivitas, perilaku pengguna, tujuan kebugaran                    | Sistem dapat memberikan rekomendasi olahraga secara otomatis, personal, dan kontekstual (real-time).                                                                   |

| No | Judul Penelitian                                                                                                                                                  | Metode yang Digunakan                                 | Variabel yang Digunakan                                       | Hasil Penelitian                                                                                                      |
|----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------|---------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
|    | <i>ontology —</i><br>Chatterjee, A.,<br>Prinz, A., Riegler,<br>M. A., & Meena,<br>Y. K. , 2023                                                                    |                                                       |                                                               |                                                                                                                       |
| 4  | <i>Supporting physical activity adoption through recommender system technology: A pilot study —</i><br>Agans, J. P., Ma, F., Schade, S., & Sciamanna, C. , 2025   | Recommender System untuk aktivitas fisik (pilot test) | Preferensi olahraga, kondisi fisik, tingkat obesitas          | Sistem membantu individu obesitas menemukan olahraga yang aman dan menyenangkan, meningkatkan adopsi aktivitas fisik. |
| 5  | <i>Effects of a personalized fitness recommender system using gamification and continuous player modeling —</i><br>Zhao, Z., Arya, A., Orji, R., & Chan, G., 2020 | Gamification + Fitness Recommender System             | Riwayat aktivitas, preferensi, model pemain (player modeling) | Gamifikasi meningkatkan motivasi jangka panjang dan keterlibatan pengguna dalam olahraga.                             |

## BAB III

### METODE PENELITIAN

#### 3.1 Tempat dan Waktu Penelitian

Penelitian dilaksanakan di Laboratorium Komputer, Fakultas Vokasi, Universitas Airlangga yang berlokasi di Kota Surabaya. Durasi Penelitian ini direncanakan berlangsung selama tujuh bulan dimulai pada Agustus 2026 dan penelitian direncanakan selesai pada kuartal pertama 2027. Dalam proses penyusunan penelitian ini memiliki rincian kegiatan yang terdapat pada **Tabel 3.1** Timeline kegiatan dibawah ini:

**Tabel 3.1 Timeline kegiatan**

| No | Aktivitas Utama                    | Bulan |   |   |   |   |   |   |
|----|------------------------------------|-------|---|---|---|---|---|---|
|    |                                    | 1     | 2 | 3 | 4 | 5 | 6 | 7 |
| 1  | Identifikasi dan Analisis Masalah  |       |   |   |   |   |   |   |
| 2  | Pengumpulan dan Persiapan Data     |       |   |   |   |   |   |   |
| 3  | Perancangan Sistem                 |       |   |   |   |   |   |   |
| 4  | Pengembangan dan Implementasi      |       |   |   |   |   |   |   |
| 5  | Pengujian dan Evaluasi             |       |   |   |   |   |   |   |
| 6  | Penarikan Kesimpulan dan Pelaporan |       |   |   |   |   |   |   |

#### 3.2 Alat dan Bahan Penelitian

Bagian ini merinci spesifikasi perangkat keras dan perangkat lunak yang digunakan sebagai sarana pendukung dalam pelaksanaan penelitian, mulai dari tahap pengolahan data hingga pengembangan sistem rekomendasi.

### 3.2.1 Perangkat Keras

**Tabel 3.2 Perangkat Keras**

| No | Perangkat        | Spesifikasi                                                 |
|----|------------------|-------------------------------------------------------------|
| 1  | Laptop/PC        | AMD Ryzen 7 5600H, RAM minimal 16 GB, SSD 512 GB            |
| 2  | Koneksi Internet | Digunakan untuk mengunduh dataset, library, dan dokumentasi |

### 3.2.2 Perangkat Lunak

**Tabel 3.3 Perangkat Lunak**

| No | Kategori           | Tools                 | Fungsi dalam Penelitian                                                                 |
|----|--------------------|-----------------------|-----------------------------------------------------------------------------------------|
| 1  | Bahasa Pemrograman | Python, HTML, CSS, JS | Bahasa pemrograman utama untuk pengembangan sistem                                      |
| 2  | Environment        | Jupyter Notebook      | Eksplorasi data (EDA), eksperimen, dan prototyping model                                |
| 3  | IDE                | Visual Studio Code    | Integrated Development Environment untuk pengembangan aplikasi                          |
| 4  | Data Processing    | Pandas                | Membaca CSV, manipulasi dataframe, merge dataset, pembersihan data                      |
| 5  | Data Processing    | NumPy                 | Operasi vektor dan matriks untuk perhitungan cosine similarity                          |
| 6  | Machine Learning   | Scikit-learn          | MinMaxScaler, OneHotEncoder, cosine_similarity, precision_score, recall_score, f1_score |
| 7  | Visualisasi        | Matplotlib            | Membuat grafik evaluasi (precision, recall, F1-score)                                   |
| 8  | Visualisasi        | Seaborn               | Heatmap korelasi atribut dan visualisasi distribusi data                                |
| 9  | Web Framework      | Streamlit             | Membangun antarmuka web sistem rekomendasi secara interaktif                            |
| 10 | Database           | PostgreSQL            | Menyimpan data pengguna, profil, riwayat aktivitas, dan feedback                        |

| No | Kategori            | Tools          | Fungsi dalam Penelitian                                       |
|----|---------------------|----------------|---------------------------------------------------------------|
| 11 | Database Driver     | psycopg2       | Library Python untuk koneksi dan query ke database PostgreSQL |
| 12 | Database Management | DBeaver        | Antarmuka visual untuk mengelola dan melakukan query database |
| 13 | Version Control     | Git + GitHub   | Version control dan penyimpanan kode sumber                   |
| 14 | Diagram             | Power Designer | Membuat diagram alur kerja dan arsitektur sistem              |
| 15 | Diagram             | StarUML        | Membuat Use Case Diagram dan Activity Diagram                 |

### 3.3 Metode Penelitian

Alur penelitian ini menggambarkan tahapan sistematis yang dilakukan peneliti dalam mengembangkan sistem rekomendasi olahraga personal untuk non-atlet. Tahapan tersebut meliputi:

#### 3.3.1 Tahap Identifikasi dan Analisis Masalah

Tahap identifikasi dan analisis masalah pada penelitian ini difokuskan secara langsung pada analisis kebutuhan untuk membedah hambatan nyata serta karakteristik spesifik yang dihadapi oleh kelompok pengguna non-atlet dalam melakukan aktivitas fisik harian. Kelompok non-atlet umumnya menghadapi kendala mendasar berupa keterbatasan pengetahuan teknis dalam menentukan jenis, durasi, dan intensitas olahraga yang aman bagi tubuh mereka, sehingga berisiko tinggi mengalami cedera fisik atau justru menghentikan rutinitas latihan secara prematur akibat beban program yang tidak sesuai. Melalui fase ini, dilakukan dekonstruksi masalah guna memetakan parameter-parameter kritis yang wajib dipasok oleh pengguna untuk membentuk pemodelan profil awal, meliputi data usia, jenis kelamin, metrik antropometri (berat badan dan tinggi badan) untuk kalkulasi Indeks Massa Tubuh (BMI) standar WHO, target

kebugaran (fitness goals), ketersediaan peralatan, serta riwayat kondisi kesehatan khusus. Seluruh parameter tersebut dianalisis secara mendalam untuk merancang kapabilitas fungsional sistem dan struktur representasi data matematis ke dalam bentuk User Feature Vector (\$U\$) dan Item Feature Vector (\$I\$), sehingga sistem dapat menjalankan logika penyaringan awal (pre-filtering) untuk mengeliminasi aktivitas berbahaya sekaligus mengoptimalkan akurasi pencocokan berbasis Content-Based Filtering sejak interaksi pertama pengguna (cold-start condition).


### **3.3.2 Pengumpulan Data**

Sumber data dalam penelitian ini sepenuhnya menggunakan data sekunder berupa empat dataset publik yang diperoleh dari platform Kaggle dalam format Comma-Separated Values (CSV). Dataset pertama adalah Gym Exercise Dataset yang memuat 2.917 data latihan dan berfungsi sebagai katalog utama jenis olahraga beserta target otot, peralatan, dan tingkat kesulitannya. Dataset kedua, Exercise and Fitness Metrics Dataset, mencakup 3.826 data yang digunakan oleh sistem untuk memperoleh estimasi pengeluaran kalori serta durasi dari aktivitas olahraga. Dataset ketiga adalah Fitness Exercises using BFP & BMI yang terdiri dari 5.000 data dan difungsikan sebagai acuan utama dalam memetakan hubungan antara kondisi fisik awal pengguna dengan target kebugaran (fitness goals) yang ingin dicapai. Terakhir, Gym Members Exercise Dataset yang memuat data dari 973 anggota gym digunakan secara khusus sebagai data simulasi profil pengguna untuk keperluan tahap pengujian fungsional serta evaluasi otomatis performa metrik pada sistem rekomendasi.

### 3.3.2 Pengembangan Model

Pengembangan model sistem rekomendasi olahraga personal untuk non-atlet dilakukan melalui beberapa tahapan terstruktur yang meliputi *preprocessing data*, rekayasa fitur (*feature engineering*), penyaringan berbasis profil (*profile-based filtering*), perhitungan kesamaan menggunakan *Weighted Cosine Similarity* (WCS), serta mekanisme pembaruan preferensi melalui *feedback loop*. Berikut adalah bagan alur kerja pengembangan sistem yang dapat dilihat pada gambar 3.1 berikut,

**Gambar 3.1 Alur Sistem**



## Langkah 1: Data Preprocessing

Tahap pertama adalah melakukan pembersihan dan persiapan data dari keempat dataset Kaggle. Proses yang dilakukan meliputi:

1. **Handling Missing Values:** Nilai kosong pada atribut numerik diimputasi menggunakan nilai median, sedangkan atribut kategorikal diimputasi menggunakan modus.
2. **Penghapusan Duplikasi:** Baris data yang memiliki nilai identik pada seluruh atribut dihapus untuk menghindari bias.
3. **Validasi Tipe Data:** Memastikan setiap atribut memiliki tipe data yang sesuai.
4. **Perhitungan BMI:** Bagi data yang hanya memiliki tinggi dan berat badan, BMI dihitung menggunakan formula:
5. **Kategorisasi BMI:** Nilai BMI dikategorikan sesuai standar WHO:

$$BMI = \frac{BB}{TB^2} \dots\dots\dots(3.1)$$

Keterangan:

- BMI = *Body Mass Index* (kg/m<sup>2</sup>).
- BB = Berat Badan (m).
- TB = Tinggi Badan (m)."

**Tabel 3.4 Kategorisasi BMI Standar WHO**

| Kategori BMI | Rentang Nilai |
|--------------|---------------|
| Underweight  | < 18,5        |
| Normal       | 18,5 – 24,9   |
| Overweight   | 25,0 – 29,9   |
| Obese        | ≥ 30,0        |

## Langkah 2: Feature Engineering

Pada tahap ini, data yang telah dibersihkan dikonversi menjadi representasi vektor numerik agar dapat dihitung kemiripannya. Proses yang dilakukan meliputi:

1. **Min-Max Scaling** untuk atribut numerik (usia, BMI, BFP, durasi, kalori) dengan formula:

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}} \dots\dots\dots(3.2)$$

Normalisasi ini mengubah seluruh nilai numerik ke rentang [0, 1] agar tidak ada atribut yang mendominasi perhitungan similarity hanya karena skala nilainya lebih besar.

2. **One-Hot Encoding** untuk atribut kategorikal (Gender, BodyPart, Equipment, Level, Workout\_Type). Contoh encoding atribut Level:

**Tabel 3.5 Contoh One-Hot Encoding Atribut Level**

| Level        | Beginner | Intermediate | Expert |
|--------------|----------|--------------|--------|
| Beginner     | 1        | 0            | 0      |
| Intermediate | 0        | 1            | 0      |
| Expert       | 0        | 0            | 1      |

3. Pembentukan Vektor: Setelah encoding, setiap profil pengguna direpresentasikan sebagai User Feature Vector (U) dan setiap item olahraga direpresentasikan sebagai Item Feature Vector (I).

Output: Vektor fitur pengguna (U) dan vektor fitur item olahraga (I) yang siap dihitung kemiripannya.

### Langkah 3: Profile-Based Filtering (Pre-filtering)

Langkah ini diadaptasi dari langkah 1 pada kerangka kerja Coppens et al. (2024). Sistem menyaring katalog olahraga berdasarkan profil dasar pengguna menggunakan aturan (*rules*) sebagai berikut:

**Tabel 3.6 Aturan Profile-Based Filtering**

| Atribut Profil     | Aturan Filter                                           |
|--------------------|---------------------------------------------------------|
| Kondisi kesehatan  | Eksklusi olahraga high-impact (lari, lompat)            |
| Kategori BMI       | Prioritaskan olahraga intensitas rendah–sedang          |
| Usia > 60 tahun    | Eksklusi olahraga dengan risiko cedera tinggi           |
| Usia < 18 tahun    | Eksklusi olahraga yang membutuhkan peralatan berat      |
| Peralatan tersedia | Hanya tampilkan olahraga yang sesuai peralatan pengguna |

Output: Subset dataset olahraga yang aman dan relevan berdasarkan profil pengguna. Langkah ini mengurangi jumlah item yang perlu dihitung similarity-nya, sehingga meningkatkan efisiensi komputasi.

### Langkah 4: Weighted Cosine Similarity (Keterbaruan 1)

Langkah ini merupakan **keterbaruan pertama** penelitian ini. Berbeda dari cosine similarity standar yang memberikan bobot sama pada setiap atribut, penelitian ini mengadaptasi konsep *student portrait* dari Gao et al. (2024) untuk memberikan **bobot adaptif** (adaptive weighting) pada setiap atribut berdasarkan profil individu pengguna.

### a. Penentuan Bobot Adaptif

**Tabel 3.7 Skema Pembobotan Berdasarkan Fitness Goal**

| Fitness Goal    | Atribut Bobot Tinggi       | Atribut Bobot Rendah |
|-----------------|----------------------------|----------------------|
| Lose Weight     | Calories_Burned, Intensity | Equipment, BodyPart  |
| Build Muscle    | BodyPart, Equipment, Type  | Calories_Burned      |
| General Fitness | Distribusi merata          | —                    |
| Flexibility     | Type (Yoga, Stretching)    | Intensity, Equipment |

Selain tujuan kebugaran, bobot juga dipengaruhi oleh kategori BMI pengguna:

**Tabel 3.8 Penyesuaian Bobot Berdasarkan Kategori BMI**

| Kategori BMI | Penyesuaian Bobot                                      |
|--------------|--------------------------------------------------------|
| Underweight  | Bobot Calories_Burned, Bobot Type (Strength)           |
| Normal       | Distribusi merata                                      |
| Overweight   | Bobot Intensity (rendah–sedang), Bobot Calories_Burned |
| Obese        | Bobot Intensity (rendah), Bobot Type (Low-impact)      |

### b. Formula Weighted Cosine Similarity (WCS)

Setelah bobot ditentukan, kemiripan antara vektor pengguna (U) dan vektor item olahraga (I) dihitung menggunakan formula berikut:

$$WCS(U, I) = \frac{\sum_{k=1}^K (w_k \cdot u_k \cdot i_k)}{\sqrt{\sum_{k=1}^K (w_k \cdot u_k^2)} \cdot \sqrt{\sum_{k=1}^K (w_k \cdot i_k^2)}} \dots\dots\dots(3.3)$$

Keterangan:

- $WCS(U, I)$  = skor kemiripan antara pengguna U dan item I (rentang 0–1)
- $w_k$  = bobot adaptif untuk atribut ke-k
- $u_k$  = nilai atribut ke-k pada vektor pengguna
- $i_k$  = nilai atribut ke-k pada vektor item
- $K$  = jumlah total atribut

Skor WCS dihitung untuk setiap item olahraga yang lolos pre-filtering (Langkah 3), kemudian diurutkan secara descending untuk menghasilkan daftar peringkat.

Output: Ranked list olahraga berdasarkan skor kemiripan dengan profil pengguna.

### **Langkah 5: Feedback Loop (Keterbaruan 2)**

Langkah ini merupakan keterbaruan ketiga yang diadaptasi dari konsep *continuous player modeling* oleh Zhao et al. (2020). Fitur ini tidak ada pada jurnal utama Coppens et al. (2024). Feedback loop memungkinkan sistem untuk memperbarui profil pengguna secara otomatis berdasarkan interaksi pengguna, sehingga rekomendasi menjadi semakin personal seiring waktu.

#### **a. Jenis Feedback yang Dicatat (Implicit Feedback)**

**Tabel 3.9 Jenis Implicit Feedback dan Sinyalnya**

| <b>Jenis Interaksi</b>             | <b>Tipe</b> | <b>Sinyal</b> |
|------------------------------------|-------------|---------------|
| Klik/simpan rekomendasi            | Positif     | +1            |
| Memberikan rating $\geq 4$ bintang | Positif     | +1            |
| Menyelesaikan aktivitas            | Positif     | +2            |
| Skip/abaikan rekomendasi           | Negatif     | -1            |
| Memberikan rating $\leq 2$ bintang | Negatif     | -1            |

## b. Mekanisme Update Bobot

Bobot vektor pengguna diperbarui menggunakan formula berikut:

$$w_k(t+1) = w_k(t) + \eta \cdot \sum_j (feedback_j \cdot i_{jk}) \dots\dots\dots(3.4)$$

Keterangan:

- $w_k(t+1)$  = bobot atribut ke-k pada iterasi berikutnya
- $w_k(t)$  = bobot atribut ke-k saat ini
- $\eta$  = learning rate (default: 0,01)
- $feedback_j$  = sinyal feedback untuk item ke-j
- $i_{jk}$  = nilai atribut ke-k pada item ke-j yang diberi feedback

## c. Interval dan Batasan Update

1. Bobot diperbarui setelah setiap sesi interaksi pengguna (minimal 3 feedback baru).
2. Setiap bobot dibatasi pada rentang  $[0,1 - 2,0]$  untuk menghindari bobot yang terlalu ekstrem.
3. Perubahan bobot per iterasi dibatasi maksimal  $\pm 10\%$  dari nilai sebelumnya (clamping).


Output: Profil pengguna yang terus diperbarui, menghasilkan rekomendasi yang semakin sesuai dengan preferensi pengguna seiring waktu.

## 3.3.3 Perancangan Sistem

Perancangan sistem ini mencakup pembuatan cetak biru fungsional aplikasi, pemodelan data relasional, serta visualisasi antarmuka pengguna untuk mengintegrasikan seluruh pipeline rekomendasi.

### 3.3.3.1 Use Case


**Gambar 3.2 Use Case Diagram**



**Gambar 3.2 Use Case Diagram** menggambarkan interaksi fungsional antara aktor *Non-Athlet* sebagai pengguna utama dengan sistem rekomendasi olahraga harian. Model fungsional ini mendefinisikan batasan sistem dan hak akses pengguna yang dimulai dari pengelolaan profil fisik awal hingga visualisasi analitik aktivitas kebugaran. Fungsi utama melihat daftar rekomendasi secara otomatis mencakup (*include*) sub-proses penyaringan keamanan standar WHO (*Pre-filtering*) dan kalkulasi matematika *Weighted Cosine Similarity* (WCS). Aliran data tersebut kemudian diperluas (*extend*) melalui penangkapan respons interaksi implisit pengguna yang bertindak sebagai pasokan data log biner bagi fungsi *Feedback Loop* untuk memperbarui profil bobot adaptif secara otomatis di latar belakang sistem.

### 3.3.3.2 Conceptual Data Model (CDM)


**Gambar 3.3 Conceptual Data Model (CDM)**



**Gambar 3.3 Conceptual Data Model (CDM)** menggambarkan struktur logis basis data dari sudut pandang konsep hubungan data tanpa keterikatan pada aspek teknis mesin database engine. Model ini memetakan hubungan logis antar-entitas utama sistem rekomendasi, yaitu `users`, `exercise_catalog`, `user_feature_weights`, dan `interaction_logs`. Sesuai dengan kaidah pencatatan formal CDM, seluruh atribut kunci tamu (Foreign Key) dieliminasi dari dalam kotak entitas dan murni direpresentasikan oleh arah garis kardinalitas relasi, seperti hubungan One-to-Many (1:N) untuk perekaman log interaksi implisit dan hubungan One-to-One (1:1) untuk pelacakan bobot adaptif model Content-Based Filtering.

### 3.3.3.3 Physical Data Model (PDM)

**Gambar 3.4 Physical Data Model (PDM)**



**Gambar 3.4 Physical Data Model (PDM)** memetakan transformasi skema konseptual (CDM) ke dalam bentuk rancangan fisik tabel relasional yang siap diimplementasikan secara nyata pada RDBMS PostgreSQL. Berbeda dengan CDM, PDM mendefinisikan aspek teknis pangkalan data secara presisi, meliputi penggunaan tipe data fisik internal PostgreSQL (seperti SERIAL, INT4, VARCHAR, dan NUMERIC) , penerapan aturan kolom wajib (NOT NULL), serta penandaan Unique Constraint (<ak>) pada atribut username. Hubungan relasional antar-tabel diwujudkan secara nyata melalui pembentukan kolom kunci tamu (Foreign Key) fisik yang dilengkapi aturan ketergantungan ON DELETE CASCADE untuk menjamin integritas data pada backend Flask.

### 3.3.3.4 High Fidelity

Rancangan tata letak antarmuka pengguna aplikasi berbasis web (Flask UI).

**Gambar 3.5 Halaman Onboarding**

HealthSync

Account Details

Username  
e.g. AlexRivers

Password  
\*\*\*\*\*

Age  
Yrs

Biological Sex  
Select

Vital Metrics

Height (cm)  
e.g. 175

Weight (kg)  
e.g. 70


Resting BPM  
~60-100

Max BPM  
Auto-calc

Simpan Profil & Buat Rekomendasi Saya

**Gambar 3.5 Halaman Onboarding** merupakan representasi antarmuka pengumpulan data pertama kali pengguna untuk menyelesaikan kendala cold-start. Halaman ini menyediakan form Account Details untuk kredensial serta seksi Vital Metrics untuk memasukkan parameter biologis mendasar seperti usia, tinggi badan, berat badan, serta denyut nadi istirahat (Resting BPM). Data dari halaman ini akan langsung dikirim oleh skrip JavaScript via POST request ke backend Flask untuk disimpan di tabel

**Gambar 3.6 Halaman Dashboard Utama**




**Gambar 3.6 Halaman Dashboard Utama** Menampilkan hasil akhir pengolahan model. Seksi atas menampilkan *Heart Rate Zones* berdasarkan kalkulasi Karvonen. Seksi tengah menampilkan komponen *Status Model* berupa progress bar dinamis nilai  $w_{body\_part}$  dan  $w_{equipment}$  yang mencerminkan transparansi jalannya algoritma. Seksi bawah menyajikan kartu rekomendasi harian (*Top-N Latihan*) yang dilengkapi tombol aksi implisit *Selesai Latihan* (sinyal +2) dan *Lewati/Skip* (sinyal -1).

**Gambar 3.7 Halaman Statistik Aktivitas**




**Gambar 3.7 Halaman Statistik Aktivitas** Memenuhi fungsionalitas visualisasi capaian pengguna. Komponen *Weekly Activity* menggunakan progress bar lingkaran untuk melacak durasi latihan kumulatif pengguna terhadap standar ambang batas aktivitas fisik aman dari WHO (150-300 menit per minggu). Komponen *Muscle Distribution* menampilkan porsi fokus kelompok otot yang paling sering dilatih berdasarkan akumulasi data histori pengerjaan olahraga.

**Gambar 3.8 Halaman Katalog Latihan**



**Gambar 3.8 Halaman Katalog Latihan** Menampilkan wujud visual dari entitas `exercise_catalog`. Halaman ini menyediakan bilah pencarian dan filter cepat kelompok otot (*Abdomens*, *Chest*) serta filter kontekstual peralatan (*Bodyweight*, *Dumbbell*). Pengguna dapat mengeksplorasi gerakan olahraga dasar secara mandiri, di mana seluruh katalog yang tampil telah melewati proses *hard-filtering* sistem (dikunci pada tingkat kesulitan *Beginner*) demi keselamatan latihan non-atlet.

**Gambar 3.9 Halaman Pusat Notifikasi**



**Gambar 3.9 Halaman Pusat Notifikasi** Menyajikan transparansi log keamanan klinis dan penyesuaian otomatis model secara real-time kepada pengguna. Kluster *Clinical Safety/Pre-filtering* akan memunculkan komponen *Critical Alert* berwarna merah menyala apabila indeks massa tubuh pengguna terdeteksi *Obese* atau memiliki riwayat cedera tertentu, mengonfirmasi secara visual bahwa sistem telah sukses mengeklusi gerakan *high-impact* berbahaya dari basis data.

### **3.3.4 Pengujian dan Evaluasi Sistem**

Pengujian sistem dalam penelitian ini dilakukan melalui dua pendekatan utama untuk memastikan keandalan model rekomendasi dan fungsionalitas perangkat lunak yang dibangun. Pendekatan pertama adalah evaluasi metrik otomatis berbasis simulasi dataset yang berfokus pada pengukuran tingkat akurasi matematis dari algoritma rekomendasi . Pendekatan kedua adalah pengujian fungsional berbasis kasus uji (*use case testing*) yang bertujuan untuk memvalidasi bahwa seluruh fitur dan aliran data pada sistem aplikasi berjalan sesuai dengan spesifikasi teknis yang diharapkan .

## DAFTAR PUSTAKA

- Agans, J. P., Ma, F., Schade, S., & Sciamanna, C. (2025). Supporting physical activity adoption through recommender system technology: A pilot study. *Journal of Health Psychology, 30*(6), 1319–1333.  
<https://doi.org/10.1177/13591053241242541>
- Chatterjee, A., Prinz, A., Riegler, M. A., & Meena, Y. K. (2023). An automatic and personalized recommendation modelling in activity eCoaching with deep learning and ontology. *Scientific Reports, 13*(1).  
<https://doi.org/10.1038/s41598-023-37233-7>
- Coppens, I., De Pessemier, T., & Martens, L. (2024). Exploring the added effect of three recommender system techniques in mobile health interventions for physical activity: A longitudinal randomized controlled trial. *User Modeling and User-Adapted Interaction, 34*, 1835–1890.  
<https://doi.org/10.1007/s11257-024-09407-z>
- Gao, W. W., Ma, H. F., Zhao, Y., Wang, J., & Tian, Q. H. (2024). Enhancing personalized exercise recommendation with student and exercise portraits. *Journal of Electronic Science and Technology, 22*(2).  
<https://doi.org/10.1016/j.jnlest.2024.100262>
- Lee, I. M., Shiroma, E. J., Lobelo, F., Puska, P., Blair, S. N., & Katzmarzyk, P. T. (2012). Effect of physical inactivity on major non-communicable diseases worldwide: An analysis of burden of disease and life expectancy. *The Lancet, 380*(9838), 219–229.  
[https://doi.org/10.1016/S0140-6736\(12\)61031-9](https://doi.org/10.1016/S0140-6736(12)61031-9)
- World Health Organization. (2020). *WHO Guidelines on Physical Activity and Sedentary Behaviour*. World Health Organization.  
<https://www.who.int/publications/i/item/9789240015128>

World Health Organization. (2022). *Global Status Report on Physical Activity 2022*. World Health Organization.

<https://www.who.int/publications/i/item/9789240059153>

Yang, Y., Huang, X., & Shi, B. (2026). Digital health interventions from the humanistic perspective of sports: Strategies to promote health for all.

Frontiers in Public Health. <https://doi.org/10.3389/fpubh.2026.1539498>

Zhao, Z., Arya, A., Orji, R., & Chan, G. (2020). Effects of a personalized fitness recommender system using gamification and continuous player modeling:

System design and long-term validation study. *JMIR Serious Games*, 8(4).

<https://doi.org/10.2196/19968>